

ΜΠΕΥΖΙΑΝΗ ΣΤΑΤΙΣΤΙΚΗ - ΕΡΓΑΣΙΑ

Μάριος Γιαννακόπουλος



University of Athens
Department of Mathematics

Μοντελοποίηση

Κάθε σετ δεδομένων αποτελείται από $n = 100$ παρατηρήσεις $x = (x_i)_{i=1}^n$ οι οποίες αφορούν στον αριθμό των βάσεων τύπου C ή G ανά παράθυρο αποτελούμενο από $m = 5000$ βάσεις. Μάλιστα, οι διαδοχικές παρατηρήσεις αντιστοιχούν σε διαδοχικά παράθυρα, επομένως κάθε σετ δεδομένων $(x_i)_{i=1}^n$ αφορά στην καταμέτρηση των βάσεων τύπου C ή G ανά παράθυρο 5000 βάσεων, ενός συγκεκριμένου τμήματος της αλυσίδας. Εάν υποθέσουμε ότι αυτό το τμήμα προέρχεται από έναν και μοναδικό ισόχωρο, τότε το ποσοστό θ των βάσεων τύπου C ή G ανά παράθυρο θα είναι σταθερό για κάθε παράθυρο του συγκεκριμένου τμήματος της αλυσίδας. Εάν επιπλέον θεωρήσουμε ότι σε οποιοδήποτε σημείο της αλυσίδας, κάθε βάση εμφανίζεται ανεξάρτητα από τις υπόλοιπες, τότε η εμφάνιση μιας βάσης τύπου C ή G σε ένα οποιοδήποτε σημείο της αλυσίδας, είναι μια τυχαία μεταβλητή που ακολουθεί κατανομή $Bernoulli(\theta)$. Επομένως, εάν θεωρήσουμε το ποσοστό θ ως τυχαία μεταβλητή, τότε $x_i | \theta \sim Binomial(m, \theta)$, $i = 1, 2, \dots, n$.

Τώρα, έστω ότι ένα σετ δεδομένων προέρχεται από δύο διαφορετικούς ισόχωρους. Τότε, δεδομένου ότι οι παρατηρήσεις προέρχονται από το ίδιο τμήμα της αλυσίδας και οι διαδοχικές παρατηρήσεις αντιστοιχούν σε διαδοχικά παράθυρα, θα υπάρχει κάποιο σημείο $t \in \{1, 2, \dots, n-1\}$ ώστε από το $(t+1)$ -οστό παράθυρο και μετά, το ποσοστό των βάσεων τύπου C ή G θα αλλάζει αισθητά.

Για να αποφανθούμε λοιπόν εάν το κάθε σετ δεδομένων προέρχεται από τον ίδιο ισόχωρο ή όχι, θα συγκρίνουμε τα δύο προαναφερθέντα μοντέλα χρησιμοποιώντας τη Μπεϋζιανή προσέγγιση. Θεωρούμε τα εξής μοντέλα:

- (i) M_1 : Για $i = 1, 2, \dots, n$, η παρατήρηση x_i είναι μια ανεξάρτητη πραγματοποίηση μίας τυχαίας μεταβλητής που ακολουθεί κατανομή $Binomial(m, \theta)$
- (ii) M_2 : Για $i = 1, 2, \dots, t$, η παρατήρηση x_i είναι μια ανεξάρτητη πραγματοποίηση μίας τυχαίας μεταβλητής που ακολουθεί κατανομή $Binomial(m, \theta_1)$.
Για $i = t+1, t+2, \dots, n$, η παρατήρηση x_i είναι μια ανεξάρτητη πραγματοποίηση μίας τυχαίας μεταβλητής που ακολουθεί κατανομή $Binomial(m, \theta_2)$.


Για να ενισχύσουμε τον αντικειμενικό χαρακτήρα της ανάλυσης και να αποτυπώσουμε την αβεβαιότητα μας για την καταλληλότητα των δύο μοντέλων, καθώς και για τις άγνωστες παραμέτρους αυτών, επιλέγουμε ίσες prior πιθανότητες για τα δύο μοντέλα, δηλαδή $P(M_1) = P(M_2) = 1/2$, καθώς επίσης επιλέγουμε και τις μη πληροφοριακές priors $\theta \sim \mathcal{U}(0, 1)$, $\theta_1 \sim \mathcal{U}(0, 1)$ και $\theta_2 \sim \mathcal{U}(0, 1)$. Επιπλέον, δεδομένου ότι η δομική αλλαγή θα μπορούσε να πραγματοποιηθεί σε οποιοδήποτε σημείο, επιλέγουμε $t \sim \mathcal{U}\{1, 2, \dots, n-1\}$.

Ανάλυση


Τα αποτελέσματα της ανάλυσης αναδεικνύουν το μοντέλο M_2 ως το καταλληλότερο για την περιγραφή των δεδομένων, για κάθε σετ δεδομένων. Μάλιστα, για κάθε σετ δεδομένων υπολογίζουμε $P(M_2 | x) = 1$ και $P(M_1 | x) = 0$, δηλαδή είναι σχεδόν βέβαιο ότι κάθε σετ δεδομένων προέρχεται από διαφορετικούς ισόχωρους.


1ο σετ δεδομένων

Εδώ το πιθανότερο σημείο δομικής αλλαγής, με βάση πάντα την posterior κατανομή του, είναι το 80ο παράθυρο.




Παρατηρούμε ότι από το 81ο παράθυρο και μετά (κόκκινο χρώμα), η ποσότητα των βάσεων τύπου C και G ανά παράθυρο κυμαίνεται μεταξύ χαμηλότερων τιμών, κάτι που φαίνεται και στο boxplot (αριστερά).






2ο σετ δεδομένων

Εδώ η διενέργεια οποιασδήποτε ανάλυσης θα μπορούσε να θεωρηθεί περιττή.




Με μια πρώτη ματιά στο σημειόγραμμα της περιεκτικότητας C/G ανά παράθυρο, παρατηρούμε απότομη και επίμονη πτώση στην εν λόγω περιεκτικότητα από ένα σημείο και μετά, γεγονός

που συνάδει με την υπόθεση ότι τα δεδομένα προέρχονται από διαφορετικούς ισochώρους. Το πιθανότερο σημείο δομικής αλλαγής είναι το 37ο παράθυρο, δηλαδή το 38ο παράθυρο ανήκει στον επόμενο ισochώρο.




Στο παρακάτω boxplot φαίνεται το εύρος των τιμών της περιεκτικότητας C/G ανά παράθυρο, σε κάθε ισochώρο. Η διαφορά είναι εμφανής.




3ο σετ δεδομένων

Το 3ο σετ δεδομένων φαίνεται να περιέχει ένα μικρό τμήμα της αλυσίδας ενός ισochώρου, στον οποίο η περιεκτικότητα C/G ανά παράθυρο, κυμαίνεται μεταξύ χαμηλότερων τιμών, ενώ στον ισochώρο που τον διαδέχεται παρατηρούμε αισθητή αύξηση στην εν λόγω περιεκτικότητα.





Εδώ η δομική αλλαγή πραγματοποιείται νωρίτερα. Συγκεκριμένα, το πιθανότερο σημείο στο οποίο αρχίζει ο επόμενος ισόχωρος, είναι το 13ο παράθυρο.




4ο σελ δεδομένων

Εδώ έχουμε την αντίθετη εικόνα από το προηγούμενο σελ δεδομένων. Τα πρώτα παράθυρα φαίνεται να ανήκουν σε έναν ισόχωρο με αυξημένο ποσοστό βάσεων τύπου C και G, ενώ στον ισόχωρο που τον διαδέχεται το ποσοστό αυτό μειώνεται αισθητά.




Το πιθανότερο σύνορο των δύο ισόχωρων είναι το 16ο παράθυρο.




5ο σετ δεδομένων

Στο 5ο σετ δεδομένων, τα τελευταία παράθυρα ανήκουν σε διαφορετικό ισόχωρο. Συγκεκριμένα, από το 72ο παράθυρο και μετά, παρατηρούμε απότομη αύξηση στον αριθμό των βάσεων τύπου C/G ανα παράθυρο.



Το πιθανότερο σημείο δομικής αλλαγής είναι το 71ο παράθυρο.



Παρακάτω βλέπουμε τη διαφορά στο εύρος τιμών της περιεκτικότητας C/G ανα παράθυρο, μεταξύ των δύο ισοχώρων.

